Ministério da Educação Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira – Inep Diretoria de Estatísticas Educacionais

Microdados do Censo da Educação Básica 2020

Manual do Usuário

Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira

Diretoria de Estatísticas Educacionais Diretor: Carlos Eduardo Moreno Sampaio

Coordenação-Geral do Censo da Educação Básica

Coordenadora-Geral: Célia Cristina de Souza Gedeon Araújo

Coordenação-Geral de Controle de Qualidade e de Tratamento da Informação

Coordenador-Geral: Fábio Pereira Bravin

Coordenação de Sistematização e Disseminação da Informação

Coordenador: Clodoaldo de Oliveira Lemes Eduardo Rodrigues de Castro Oliveira Maria das Dores Pereira Rosa Maruska Pereira de Almeida Melissa Riani Costa Machado Palu Silveira Abe Silvana Porto de Araújo Fernandes

Coordenação de Estatísticas, Indicadores e Controle de Qualidade do Censo da Educação Básica

Coordenador: Vitor Passos Camargos Carla Rodrigues Costa de Araújo Helena Ariane Borges Corrêa Júlio César de Lima Filgueiras Laís Raiane Miguel Amaral Márlei Afonso de Almeida Raphael Igor da Silva Corrêa Dias

Apresentação

O Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep), autarquia vinculada ao Ministério da Educação, tem como missão institucional produzir e disseminar informações educacionais. As estatísticas e avaliações produzidas pelo Inep visam fornecer os subsídios para a formulação e implementação de políticas voltadas para a melhoria contínua da educação no país.

O Inep desenvolve uma série de ações de disseminação de dados que se encontram disponíveis no Centro de Informações e Biblioteca em Educação (Cibec), organizado para atender presencialmente aos usuários, e em seu site (https://www.gov.br/inep/pt-br/areas-de-atuacao/gestao-do-conhecimento-e-estudos-educacionais/cibec).

O presente documento figura entre os instrumentos utilizados por este Instituto para garantir a transparência requerida pela sociedade e promover a participação dos diferentes agentes sociais envolvidos nas ações educativas.

Nesse contexto, os Microdados passaram a ser estruturados em formato CSV (Comma-Separated Values), e seus dados estão delimitados por *Pipe* (|), de modo a garantir que praticamente qualquer software estatístico, inclusive *open source*, consiga importar e carregar as bases de dados.

Devido à amplitude de nossas bases, os arquivos foram divididos por região geográfica (Norte, Nordeste, Sudeste, Sul e Centro-Oeste), tanto para as variáveis de Matrículas, quanto para as de Docentes.

Por meio dos Microdados é possível obter um amplo panorama da educação brasileira e, como importante ferramenta de transparência, é indubitavelmente um rico acervo sobre a educação básica do nosso país e uma fonte segura e eficaz de obtenção de dados, acessíveis aos pesquisadores, estudantes, gestores e sociedade em geral.

Sumário

- 1 DIRETÓRIOS
- ${\bf 2}$ ORIENTAÇÕES PARA ABRIR OS ARQUIVOS CSV NO SOFTWARE R
- 3 ORIENTAÇÕES PARA ABRIR OS ARQUIVOS CSV NO SOFTWARE SPSS
- 4 ORIENTAÇÕES PARA ABRIR OS ARQUIVOS CSV NO SOFTWARE SAS
- **5 CONTATO**

1 - Diretórios

DADOS

Encontra-se neste diretório as bases de Escolas, Matrículas, Docentes, Turmas e Gestor, estruturadas no formato CSV (Comma-Separated Values), delimitados por *Pipe* (|). Informamos também que todos os Microdados de 1995 até a edição mais recente da pesquisa censitária estão disponíveis para download no portal do Inep, na internet, segue o endereço: https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/microdados.

LEIA-ME

Este presente instrumento traz instruções fundamentais para a correta extração e manipulação dos dados educacionais. É importante enfatizar que os Microdados estão estruturados em CSV (Comma-Separated Values), que é basicamente uma implementação de arquivos de texto separados por um delimitador (pipe), sendo compatível com praticamente qualquer sistema moderno, incluindo: softwares estatísticos ou de manipulação de dados, servidores de dados e planilhas eletrônicas (Excel, Calc, etc), conforme formatos adotados ou recomendados pelos Padrões de Interoperabilidade de Governo Eletrônico – ePING.

Como sugestão, disponibilizamos neste documento algumas orientações para abrir os arquivos nos principais softwares estatísticos e de acesso à base de dados utilizados pelos pesquisadores, que permitem o acesso, manipulação, análise e apresentação de informações, tais como o R (que é *open source*, composto por linguagem e ambiente de desenvolvimento integrado para cálculos estatísticos e relatórios), IBM SPSS e SAS (Statistical Analysis System).

Cabe ressaltar também que disponibilizamos junto ao "Leia-Me", uma Nota Explicativa sobre o tratamento aplicado em 2020 aos campos de quantitativo e também aos campos não aplicáveis e não informados nas bases do Censo Escolar.

FILTROS DA EDUCAÇÃO BÁSICA

É um documento que norteia o usuário na obtenção de dados corretos e em sintonia com os valores publicados nas Sinopses Estatísticas. Nele, são elencados, de forma simples, os principais filtros e funções que devem ser aplicados nas diferentes etapas e modalidades de ensino, considerando as quatro tabelas principais: Escola, Turma, Matrícula e Docente.

ANEXO I - Dicionário de Dados e Tabelas Auxiliares

- Contém, em formato .xlsx (Excel), os seguintes Dicionários das Variáveis do Censo da Educação Básica 2020:

- Dicionário de Dados:

- TABELA DE ESCOLA
- TABELA DE TURMA
- TABELA DE MATRÍCULA
- TABELA DE DOCENTE
- TABELA DE GESTOR

- Tabelas Auxiliares

- TABELA DE LÍNGUAS INDÍGENAS
- TABELA DE CURSOS DA EDUCAÇÃO PROFISSIONAL TÉCNICA
- TABELA DE TIPO DE ATIVIDADE COMPLEMENTAR POR CATEGORIA/ÁREA
- TABELA DE PAÍSES
- TABELA DE CURSOS DE FORMAÇÃO SUPERIOR

- TABELA DE IES
- TABELA DE ETAPA DE ENSINO
- TABELA DE ÁREAS DO CONHECIMENTO / COMPONENTES CURRICULARES
- TABELA DE ÓRGÃOS REGIONAIS DE ENSINO
- TABELA DE UNIDADES DA FEDERAÇÃO E MUNICÍPIOS

ANEXO II - Questionários do Censo da Educação Básica

Contém, em formato .pdf (Portable Document Format), os seguintes questionários do Censo da Educação Básica 2020:

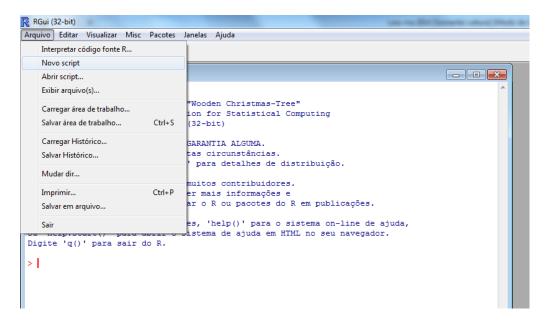
- Cadastro_Aluno
- Cadastro_Escola
- Cadastro_Gestor_Escolar
- Cadastro_Profissional_Escolar
- Cadastro_Turma

É importante ressaltar que os Microdados, em consonância com a legislação que estabelece critérios para o acesso aos dados pessoais, disponibiliza somente em suas bases os dados públicos coletados pela pesquisa censitária.

2 - ORIENTAÇÕES PARA ABRIR OS ARQUIVOS CSV NO SOFTWARE R

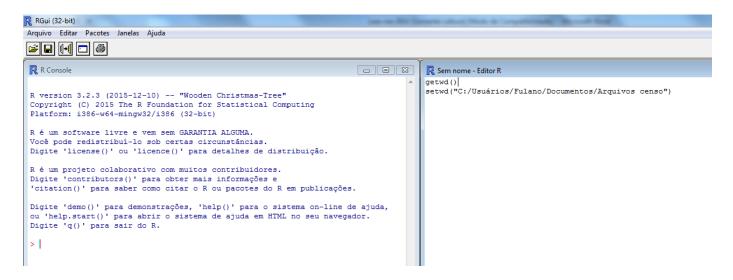
2.1 - Abertura de bases pequenas (ESCOLAS e TURMAS):

1) Abra um Novo *script* clicando na aba "Arquivo" → "Novo script".



2) Certifique-se de que o Diretório de Trabalho no R corresponde ao local onde estão presentes os arquivos. Copie o comando abaixo e cole na nova janela aberta. Atenção: Para rodar cada comando, posicione o cursor do mouse na linha do comando e pressione Ctrl+R. Alternativamente, o comando pode ser copiado e colado diretamente no console.

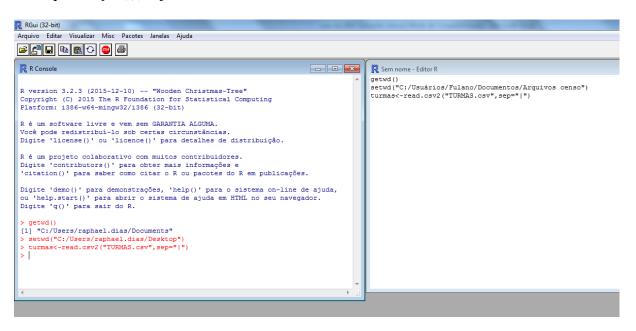
getwd() #Se o caminho não estiver correto, use a função a seguir para alterá-lo: setwd("C:/Usuários/Fulano/Documentos/Arquivos censo") #Exemplo de caminho. Lembre-se de usar barra simples ("/") ou barra invertida dupla ("\\").



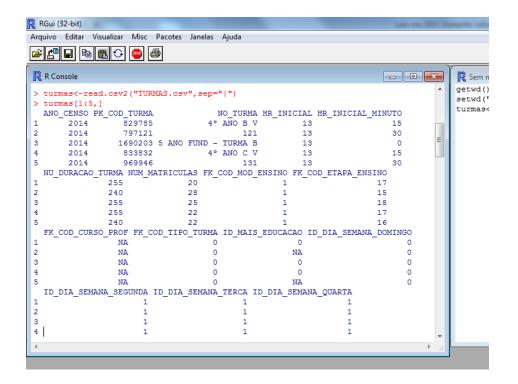
3) Para abrir, por exemplo, a base "TURMAS.csv", copie o comando abaixo e cole no *script*. Rode o comando pressionando Ctrl+R.

turmas<-read.csv2("TURMAS.csv",sep="|")

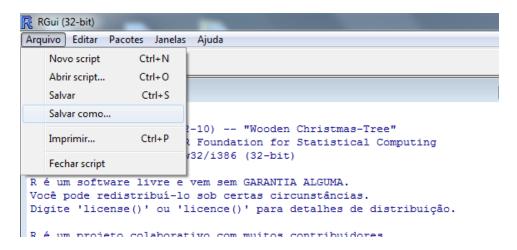
É importante que o *Pipe* (|) seja utilizado como delimitador.



4) Após esses procedimentos, a base de dados já estará aberta, permitindo sua análise. Para conferir se a base foi lida corretamente, é possível visualizar algumas linhas copiando o comando abaixo e colando no *script*. Rode o comando pressionando Ctrl+R. Nesse exemplo, são visualizadas as cinco primeiras linhas de cada coluna. turmas[1:5,]

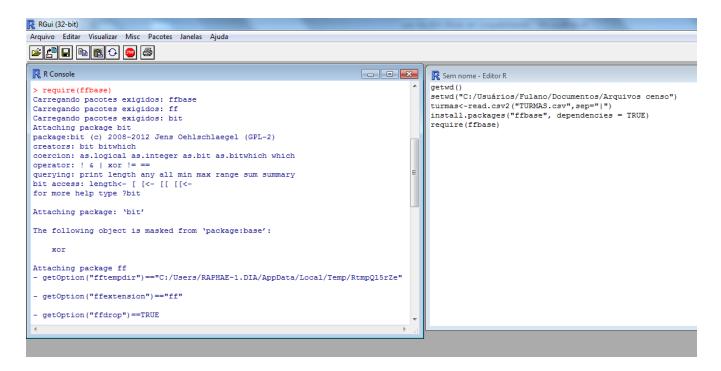


5) Sugerimos salvar o *script* criado para posterior utilização. Acesse a aba "Arquivo" → "Salvar como...".



2.2 - Abertura de bases maiores (MATRÍCULAS e DOCENTES):

- 1) O software R, como padrão, trabalha com as bases de dados utilizando a memória RAM do computador. Entretanto, o carregamento de bases muito grandes (por exemplo, mais de 1 milhão de linhas) utilizando a leitura tradicional (como "read.table" ou "read.csv") pode sobrecarregar o computador, ou mesmo resultar em erro por falta de memória. Dessa forma, para a leitura das bases de MATRÍCULAS e DOCENTES, que possuem mais de 10 milhões de linhas (Brasil), faz-se necessário o uso de pacotes adicionais. Sugerimos o uso do pacote "ffbase" para trabalhar com essas bases, tendo em vista que o mesmo faz uso do disco rígido em detrimento da memória RAM. Evidentemente, as bases de ESCOLAS e TURMAS também podem ser carregadas utilizando esse pacote, sendo recomendável quando houver necessidade de cruzar informações entre as bases. O pacote "ffbase" armazena a base de dados no R como um objeto da classe "ffdf" diferentemente da leitura tradicional, que gera um objeto da classe "data.frame". O objeto "ffdf" também permite a aplicação de algumas funções – não todas – que são utilizadas com objetos da classe "data.frame" (por exemplo, "table", "merge" e "transform"). Para aplicação de filtros nas bases "ffdf", recomendamos o uso da função "ffwhich" (veja a ajuda da função para maiores informações: "?ffwhich"). Além disso, para concatenar as bases de cada região (as bases Docentes e Matrículas estão separadas por região), uma abaixo da outra, é necessário utilizar a função "ffdfappend" (para mais informações: "?ffdfappend"). Informações adicionais estão disponíveis na ajuda do pacote (https://cran.r-project.org/web/packages/ffbase/ffbase.pdf).
- 2) Ainda utilizando o mesmo *script*, instale o pacote necessário para a manipulação de bases maiores (ffbase) copiando e colando os comandos abaixo. Rode os comandos pressionando Ctrl+R. install.packages("ffbase", dependencies = TRUE) #Instala o pacote require(ffbase) #Carrega o pacote

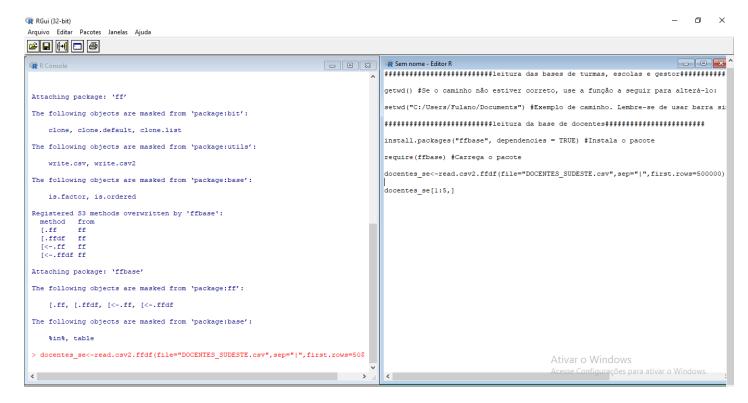


- 3) Caso você tenha aberto um novo *script*, será necessário certificar-se novamente de que o Diretório de Trabalho no R corresponde ao local onde estão presentes os arquivos por meio dos mesmos comandos já citados anteriormente:
 - getwd() #Se o caminho não estiver correto, use a função a seguir para alterá-lo: setwd("C:/Usuários/Fulano/Documentos/Arquivos censo") #Exemplo de caminho. Lembre-se de usar barra simples ("/") ou barra invertida dupla ("\\").

4) Para abrir o arquivo "DOCENTES_SUDESTE.csv", por exemplo, copie o comando abaixo e cole no *script*. Rode o comando pressionando Ctrl+R. O atributo "first.rows" determina a quantidade de linhas utilizadas para que o programa perceba o tipo/categoria das variáveis.

docentes_se<-read.csv2.ffdf(file="DOCENTES_SUDESTE.csv",sep="|",first.rows=500000)

É importante que o *Pipe* (|) seja utilizado como delimitador.



Caso, ainda assim, o usuário enfrente problemas de uso da memória RAM para leitura da base de docentes ou de matrículas, as opções a seguir podem também ser utilizadas:

a) Elevação do limite da memória

O teste de memória abaixo identifica o limite de memória que está sendo utilizado. No campo "size" é possível definir um valor de memória maior que do que aquele que está sendo usado pelo R. A elevação do limite de memória deve ser realizada antes da leitura da base de dados.

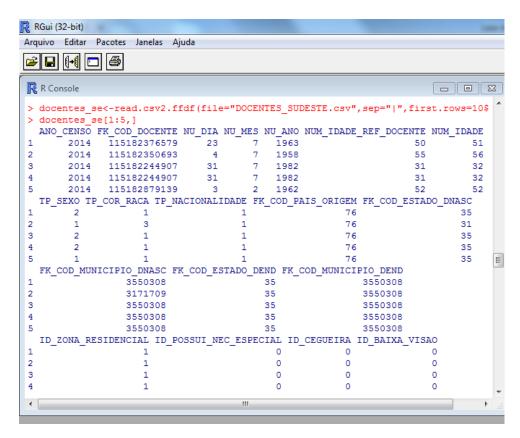
memory.limit() #memória limite atual memory.limit(size = 20000) #exemplo de elevação do limite para aproximadamente 20 gigabytes memory.limit() #verificação

b) Uso do options

Outra alternativa para contornar problemas de memória é usar o "options" antes de executar o comando de leitura das bases de dados, da seguinte forma:

options (ffmax bytes=min(get Option ("ffmax bytes"),. Machine \$integer.max*12), ffbatch bytes=10000000)

- 5) Bases grandes, quando carregadas pela primeira vez, podem demorar alguns minutos para concluir o processamento (dependendo das configurações do computador). Sugerimos salvar a base no formato 'ffdf' para que uma nova carga inicial não seja necessária numa próxima sessão. save.ffdf(docentes_se, dir="./docentes_se")
- 6) Dados salvos no formato 'ffdf' podem ser carregados em um outro momento utilizando o comando abaixo. O carregamento da base com a função abaixo é praticamente instantâneo. load.ffdf(dir="./docentes_se")
- 7) Após esses procedimentos, a base de dados já estará aberta, permitindo sua análise. Para conferir se a base foi lida corretamente, é possível visualizar algumas linhas copiando o comando abaixo e colando no *script*. Rode o comando pressionando Ctrl+R. Nesse exemplo, são visualizadas as cinco primeiras linhas de cada coluna. docentes_se[1:5,]



8) Como citado anteriormente, o pacote ffbase permite a manipulação das bases de dados com funções semelhantes àquelas conhecidas para data frames. A seguir, apresentamos exemplos de seleção de variáveis, seleção de matrículas de escolarização, frequência por UF, merge entre as bases de escola e matrículas e recodificação de variáveis.

###funções ffbase para manipulação das bases de matrículas###

```
matricula_se<-read.csv2.ffdf(file="MATRICULA_SUDESTE.csv",sep="|",first.rows=500000)
```

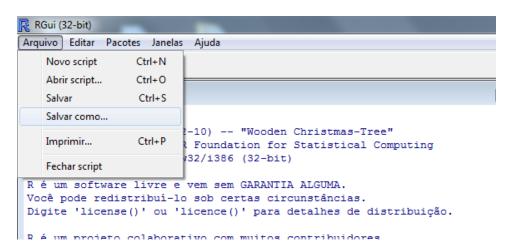
#seleção de variáveis e filtro de linhas na base de matrícula

#matrículas de escolarização

filtro <- ffwhich(matricula_se, TP_TIPO_ATENDIMENTO_TURMA ==1 |

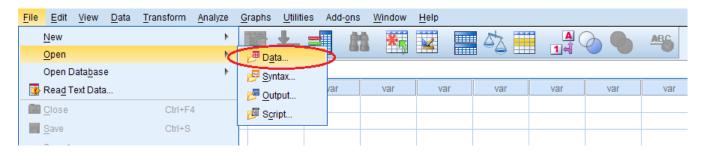
```
TP_TIPO_ATENDIMENTO_TURMA ==2)
base filtro= matricula se[filtro,]
variaveis_mat=c('CO_ENTIDADE','CO_UF','CO_MUNICIPIO','TP_DEPENDENCIA','TP_LOCALI
ZACAO', 'TP_ETAPA_ENSINO', 'ID_MATRICULA', 'TP_TIPO_ATENDIMENTO_TURMA')
base filtro<-base filtro[variaveis mat]
base_filtro[1:5,]
table(base_filtro$CO_UF)
table(base_filtro$TP_TIPO_ATENDIMENTO_TURMA)
###leitura da base de escolas para merge com a base de matrículas
escolas2<-read.csv2.ffdf(file="ESCOLAS.csv",sep="|",first.rows=100000)
escolas2[1:5,]
variaveis_esc = c('CO_ENTIDADE','NO_ENTIDADE','TP_LOCALIZACAO_DIFERENCIADA')
escolas2<-escolas2[variaveis_esc]
me <- merge( base_filtro, escolas2, by = "CO_ENTIDADE")
####recodificação de uma variável
me2<-transform(me, TP_DEPENDENCIA_2=
                   cut(ifelse((TP_DEPENDENCIA<=3),1,2),2,labels=c("Público","Privado"))
me2[1:5,]
```

9) Sugerimos salvar o *script* criado para posterior utilização. Acesse a aba "Arquivo" "Salvar como...".

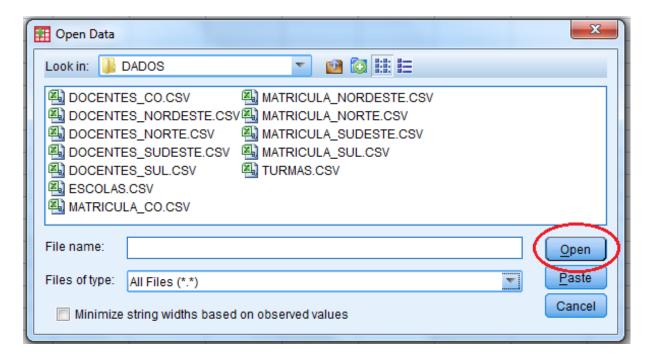


3 - ORIENTAÇÕES PARA ABRIR OS ARQUIVOS CSV NO SOFTWARE SPSS

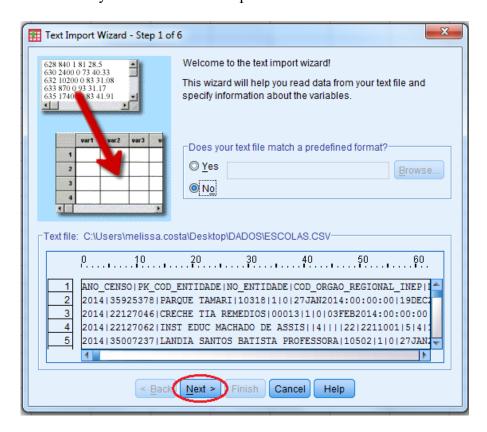
1) Abrir uma planilha no software SPSS e clicar na aba "File"→ "Open"→ "Data".



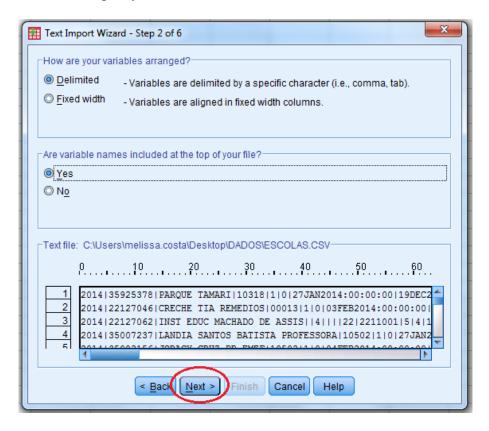
2) Em seguida, selecionar em "Files of type" a opção "All Files (*.*)", para que os arquivos em formato CSV possam ser visualizados. Selecionar o arquivo CSV desejado e clicar em "Open". No exemplo, os arquivos estão na pasta DADOS.



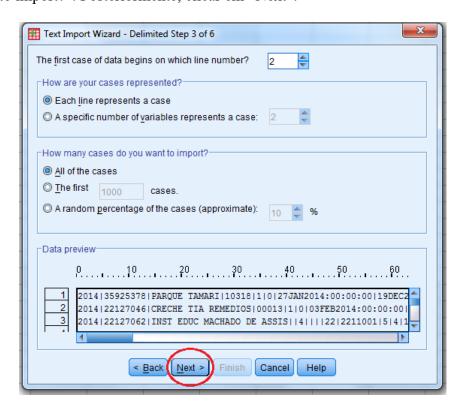
3) Manter a opção "No" em "Does your text file match a predefined format?" e clicar em "Next".



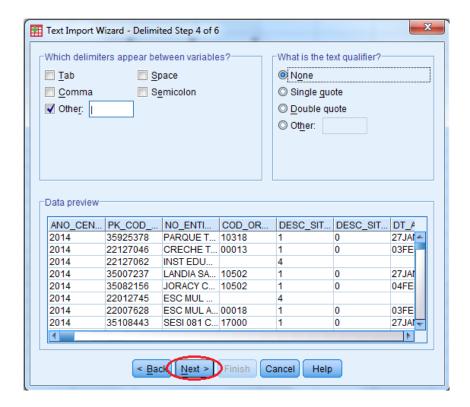
4) Manter a opção "Delimited" em "How are your variables arranged?" e alterar para a opção "Yes" em "Are variable names included at the top of your file?". Posteriormente, clicar em "Next".



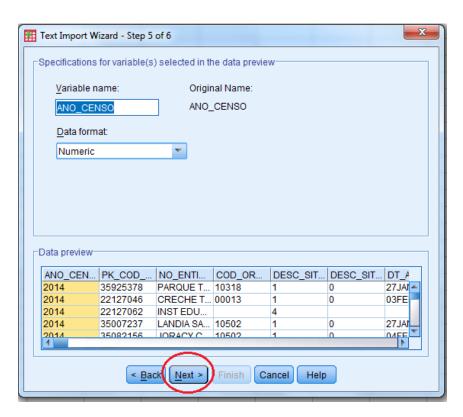
5) Manter a opção "2" em "The first case of data begins on which line number?". Manter, também, as opções "Each line represents a case" em "How are your cases represented?" e "All of the cases" em "How many cases do you want to import?". Posteriormente, clicar em "Next".



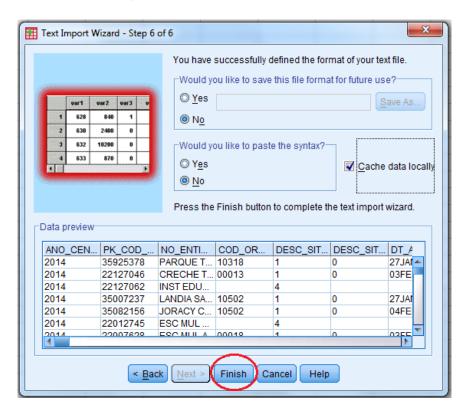
6) Desmarcar a opção "Space" e marcar a opção "Other" em "Which delimiters appear between variables?", utilizando o *Pipe* (|) como delimitador. Manter a opção "None" em "What is the text qualifer?". Posteriormente, clicar em "Next".



7) Manter as opções marcadas em "Specifications for variable(s) selected in the data preview" e clicar em "Next".

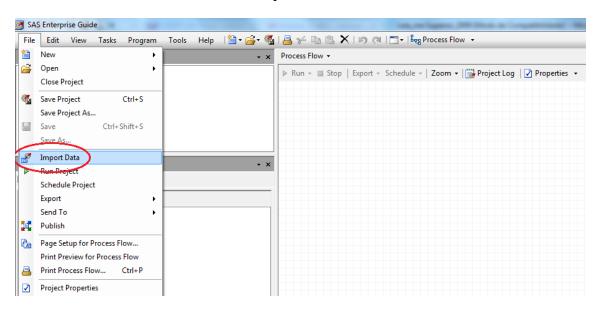


8) Na última etapa de "Text Import Wizard", é possível optar entre "Yes" e "No" em "Would you like to save this file format for future use?" e em "Would you like to paste the syntax?". Para finalizar o processo de importação de dados no software SPSS, basta clicar em "Finish".

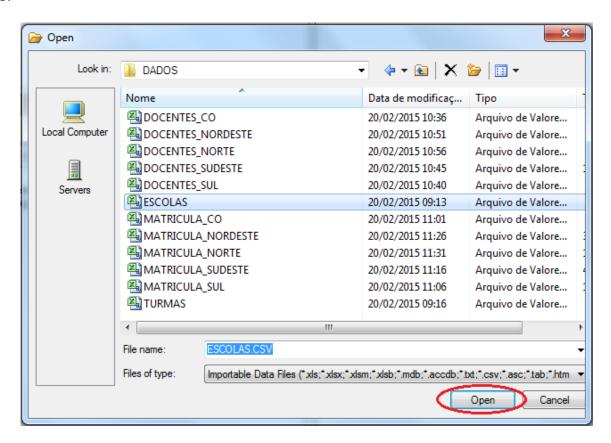


4 - ORIENTAÇÕES PARA ABRIR OS ARQUIVOS CSV NO SOFTWARE SAS

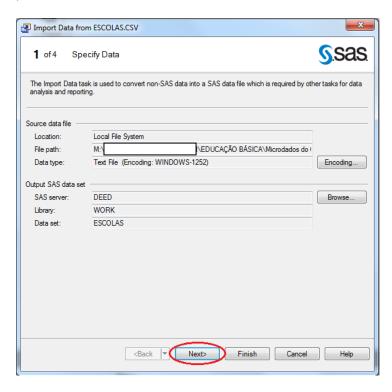
1) Abrir o software SAS e clicar na aba "File"→ "Import Data".



2) Em seguida, selecionar o arquivo CSV desejado e clicar em "Open". No exemplo, os arquivos estão na pasta DADOS.



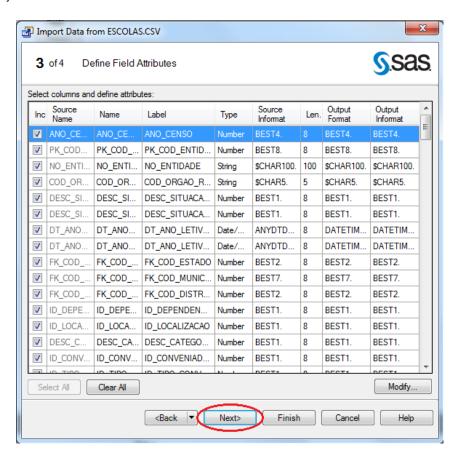
3) Na etapa seguinte, mantêm-se as opções marcadas em "Source data file" e pode-se optar pelo local onde será o *Output* da planilha. Após, clicar em "Next".



4) Manter a opção "Delimited fields" em "Text format" marcada e manter o *Pipe* (|) como delimitador. Manter as demais configurações, como a caixa de "File contains field names on record number:" marcada e o número 1 preenchendo o campo à frente, e manter em "Data records start at record number:" o número 2 preenchendo o campo à frente. Posteriormente, clicar em "Next".



5) Manter as configurações e clicar em "Next".



6) Para finalizar o processo de importação de dados no software SAS, basta clicar em "Finish".



5 - Contato

A Diretoria de Estatísticas Educacionais do Inep disponibiliza o seguinte correio eletrônico para prestar suporte técnico aos usuários dos Microdados: <u>dadosabertos.deed@inep.gov.br</u>. Lembrando que esse e-mail não recebe solicitação de dados. Para solicitar dados ou informações ao Inep, formalize seu pedido por meio do Serviço de Informação ao Cidadão (SIC): https://www.gov.br/inep/pt-br/acesso-a-informacao/servico-de-informacao-ao-cidadao-sic